

Building Application for Detection of Damaged Road by using Deep learning.

基于深度学习的受损道路检测建筑应用

简介:

道路对一个国家的城乡建设十分重要性，因为它们对人们的日常生活至关重要。它们对于将人员和货物运送到需要的地方至关重要，而这反过来又会刺激经济并帮助其蓬勃发展。道路对人们的日常生活至关重要，因为它们让人们去工作、上学、医院和其他他们需要的地方。它们有助于个人上下班，会见朋友和家人，并参加其他社会活动。一个地区的道路状况在很大程度上影响着人们去需要去的地方的速度和方便程度。

道路对一个国家的经济也很重要。他们在促进制造商、零售商和最终用户之间商品和服务的顺畅流动方面发挥着至关重要的作用。发达的公路网降低了企业的运输成本，使企业能够以更低的成本将货物运往新的市场，从而使企业受益。生产力提高，产量提高，经济增长是效率的结果。让人们有工作是修建和维护道路的另一个好处。公路建设项目直接或间接地雇用了成千上万的人。修路是直接就业的一个来源，而材料和劳动力的供应，如汽油、工具和维修服务，是另一个来源。持续的道路投资可以促进经济，创造新的就业机会，提高人民的生活水平。

尽管如此，人们的正常生活和一个国家的经济可能会因道路受损而严重中断。当交通事故、交通堵塞和通勤时间延长是由道路不达标引起的时，生产力会受到打击。修复和维护破损的道路可能相当昂贵，占用了本可以用于其他经济建设的资金。此外，糟糕的路况可能会限制投资，降低企业竞争力。由于运输成本上升、交货延迟延长以及恶劣路况导致的利润率下降，企业的利润可能会受到打击。如果这种情况继续下去，经济增长和进步可能会受到阻碍。此外，道路恶化可能产生社会影响，特别是在农村地区。由于糟糕的道路状况，社区可能会变得孤立，使居民难以获得医疗、教育和职业前景等重要服务。这种情况可能会导致机会减少、生活水平降低和贫困加剧。

此外，损坏的道路会影响环境。路面的坑洼和裂缝会导致车辆排放更多的废气，导致空气污染。水也会聚集在坑洼处，造成侵蚀，导致土壤和水的污染。损坏的道路有很多种分类。损害的类型和强度是一个典型的分类。这里有几个这样的例子:

1. 坑洞:这些是由交通磨损、天气状况和维护不当造成的道路上的微小到中等大小的洞。
2. 裂缝:这些是路面上的小裂缝，如果不立即纠正，可能会变成更大的洞。
3. 车辙:是由于大负荷、重复驾驶、排水不良在路面上产生的凹陷或沟槽。

4. 粗糙度:这是指路面的不平整程度, 会引起乘客的不适和车辆的损坏。
5. 天坑:这些是由于地下基础设施故障或土壤侵蚀造成的路面上巨大的、意想不到的洼地。
6. 洪水:在暴雨或洪水发生时, 这是一个典型的问题, 可能会破坏路面, 冲毁桥梁, 阻碍交通。

在这个项目中, 我们特别关注了 4 种类型的伤害。基于视图的三种不同类型的裂缝, 车辙、凹凸、坑洼和分离是本检测项目[1]的类别。该项目的目的是开发一种技术, 使用先进的计算机视觉算法, 可以自动检测各种类型的道路损坏, 如坑洼、裂缝和其他缺陷。其基本思想是使用模仿人脑的深度学习算法, 识别已知损坏道路的图像或视频中的模式, 并使用这些信息在新的图像或视频或实时镜头中识别类似的损坏。深度学习和计算机视觉已经彻底改变了目标检测领域。物体检测是在图像或视频流中识别感兴趣的物体的过程, 它有许多实际应用, 如监控、自动驾驶和医学成像。深度学习是机器学习的一个子集, 它使得复杂的对象检测算法的开发成为可能, 即使在复杂和混乱的场景中, 也可以准确地检测和定位感兴趣的对象。卷积神经网络(CNN)等深度学习模型在从图像中学习特征和模式方面特别有效, 这使它们能够很好地推广到新数据。图像分割和目标跟踪等计算机视觉技术也通过提供有关被检测对象的额外上下文和信息来补充深度学习方法。深度学习和计算机视觉一起为目标检测开辟了新的可能性, 应用范围广泛, 从医疗保健到交通运输。

人体和物体检测技术对检测受损道路产生了重大影响。从历史上看, 人工检查员用肉眼检查道路的是否损坏, 如裂缝、坑洼和其他问题。不幸的是, 这种方法既费时又费钱, 而且检查的质量和一致性取决于检查员的经验和知识。物体检测技术使得自动道路检查成为可能, 使用摄像头和其他传感器来检测和识别劣化指标。有可能教会机器学习算法识别受损道路的模式和特征, 使它们能够检测到即使是最微小的恶化指标。这项技术有可能提高道路检查的精度和效率, 节省费用, 并提高驾驶员的安全性。此外, 将人类经验与物体检测技术相结合, 可以进一步提高检查的准确性, 因为人类检查人员能够理解和评估机器学习算法的输出, 从而就道路维护和维修提出有根据的建议。使用物体检测技术进行道路检查可以节省成本。传统的道路检查方法既耗时又昂贵, 因为他们需要检查人员前往现场, 对道路进行物理评估, 并记录他们的发现。相比之下, 物体检测技术可以通过在车辆或基础设施上安装摄像头和其他传感器来实时记录数据来实现自动化。这可以减少对人工检查人员的需求, 减少检查成本和时间。此外, 应用机器学习算法来评估数据可以产生更精确和一致的结果, 使道路维护和维修更有针对性, 并降低昂贵和不必要的维修的可能性。此外, 早期诊断道路损坏可以防止更严重的损坏, 并减少未来更昂贵的维修或重建的需要, 从而节省资金。人体和物体探测技术对探测受损道路的影响在提高我们交通基础设施的安全性和寿命方面具有相当大的潜力。因此, 在道路检查中使用物体探测技术有可能通过提高检查的效率和准确性以及更有效地集中道路维护和维修来节省资金。



图 1: (a) 基于 CRDDC-2022 数据集[1]的受损道路样本

在这个项目中，我们改进了 YOLO (You Only Look Once)算法来检测和分类损坏类型的道路。这项技术的目标是通过更快、更准确地检测道路损坏来提高道路安全。它还有助于降低维护成本，并通过更早地发现损坏情况，以便及时进行维修，从而延长道路的使用寿命。该项目使用的关键技术是深度学习算法，这些算法是在带有注释的道路损坏的道路图像和视频的大型数据集上进行训练的。这些算法可以通过分析数千张已知损坏的道路图像和视频来识别特定类型的损坏。一旦经过训练，这些算法就可以在现场部署，使用安装在车辆或无人机上的摄像头，或通过分析现有的道路视频片段，实时检测道路损坏情况。

基于深度学习项目的道路损伤检测的主要技术指标是检测不同类型道路损伤的准确性。这通常是通过评估算法在带有注释损伤的图像和视频的单独数据集上的性能来衡量的。算法的精度越高，就越能在现实条件下检测和定位道路损坏。其他技术指标可能包括处理速度、内存使用和算法的能源效率。

该项目的新颖之处在于它能够简化和加强交通运输，同时也有助于有关部门识别和修复受损路段。这项工作的主要目标是开发一个用户友好的检测模型，可以在移动电话和计算机系统上实现。该模型可进一步应用于安全摄像头、无人机或手机摄像头。本研究的另一个主要目标是通过降低计算复杂度和增加可访问性来改进现有的检测模型。预计该模型即使在处理大型图像时也需要更少的内存，从而更有效地解决决策和记录问题。这项工作的技术指标包括准确性、处理速度、内存使用率和能源效率。这些指标将被评估，以确定所提出的模型的有效性和效率。此外，为了方便用户使用该检测模型，我们还为该项目开发了计算机辅助应用程序。通过使用这个应用程序，相关部门可以在实时工作中使用我们的检测模型，也可以在视频和片段中单独使用。这个应用程序还将有助于减少计算和评估检测模型结果所消耗的时间。

详细介绍：

利用深度学习技术进行道路损伤检测是近年来备受关注的研究领域。这一领域的特点是其科学性和先进的技术创新。深度学习模型已被用于检测各种类型的道路损坏，包括坑洼、裂缝和其他缺陷。这些模型基于神经网络，旨在从道路图像和视频的大型数据集中学习。深度学习算法的使用使得开发更准确、更高效的检测模型成为可能，可以高精度、快速地识别道路损坏。此外，该项目的先进性体现在使用各种技术来收集数据，包括无人机、移动摄像头和安全摄像头。然后通过深度学习算法处理捕获的数据，该算法能够处理大量数据并做出准确的预测。此外，研究人员正在探索提高这些模型的可访问性和可用性的新技术，例如开发可以在移动电话和其他设备上实现的用户友好界面。

方法论:

本项目的技术前景如下:

(1)确定并选择最优的图像数量作为训练数据集。被称为基于众感的道路损伤检测挑战(CRDDC2022)的数据集用于本研究的目标[1-7]。该数据集包含来自各个国家的约 50,000 张图像，用于培训和测试目的。使用此数据集的主要目的是使检测器模型熟悉无数可能的道路损坏场景。这样做是为了确保该模型在全球任何国家或地区的适用性。

(2)在开始工作之前，必须对这个数据集中包含的图像进行预处理，然后再进行处理。要实现这一点，首先必须将图像和注释转换为 JSON 文件，同时遵循 PASCAL VOC 数据集行为准则，这取决于哪种格式适合模型。图像增强是一种可以通过使数据集更全面来提高数据集训练特定模型的适用性的过程。图像优化技术，如高斯模糊增强方法，以不同角度旋转图像中的物体，调整纯粹值，以及许多其他类似的技术都非常重要。通常，这是从图像中提取特征的更有效的方法之一，这对探测器模型很重要。

(3)循环神经网络[8]，卷积神经网络[9]和长短期记忆网络是三种最常用于深度学习模型合并的神经网络。特别是，卷积神经网络是一种强大的工具，可用于图像分析以及预测模型的开发。有许多不同的算法可用于定位对象，包括 R-CNN, EfficientNet [10]，ImageNet [11]，SSD [12]，YOLO [13]，Detectron2[14]，以及其他许多算法。与 YOLO 相比，SSD 使用 CNN 进行目标检测更加高效、快速，而不是等到完全链接层完成后。SSD 将提取不同规模的特征图用于检测。早期创建的大比例尺特征图可用于识别小物体，而后期创建的小比例尺特征图可用于检测大型物体。SSD 使用各种大小和纵横比的早期盒子。SSD 的检测速度比 R-CNN 快，但检测精度不如 R-CNN。然而，YOLO 反之亦然。虽然 R-CNN 的速度比其他方法慢，但在寻找大型物体时还是相当有效的。在这种情况下，快速 R-CNN[15]或掩码 R-CNN[16]可用于实验目的。因此，我们选择 YOLO 算法作为我们的最终结果。

(4)技术任务将使用以下内容:

操作	算法库
计算	NumPy
数据集处理	ElementTree, Pandas, Json
图像处理与可视化	OpenCV, Matplotlib
增加画面	Keras
模型架构设计，模型培训，模型微调	PyTorch

其他	OS, BeautifulSoup, pickle
----	---------------------------

此外，Windows 10 也将被用作电脑操作系统的平台。编程语言将是 Python，集成开发环境将是 Jupyter Notebook (IDE)或 Anaconda。这将使部署和可视化更加容易。

提出的模型:

高效的道路养护需要可靠的监控系统，直观的方法是人工目视检查;然而，由于昂贵、费力和耗时，这是不可行的。因此，研究人员开发了多种道路损伤自动检测解决方案，包括基于振动的[17]、基于激光扫描的[18]和基于图像的方法[19-22]。而振动方法的检测仅限于道路的接触部分，激光扫描方法提供了有关道路状态的准确信息;然而，这种方法很昂贵，而且需要封闭道路。与此同时，图像处理价格低廉，但可能缺乏准确性。尽管图像分析技术还不成熟，但最近的进步已经产生了令人印象深刻的结果，从而增加了其在各种应用中的使用(例如，街道清洁[23]，交通流分析[24]，灾害态势感知[25]和图像搜索[26])。一些研究人员使用最先进的深度学习方法开发了基于图像的路面检测方法。特别是，一些工作只关注于检测损害的存在，而不管其类型[19]。其他工作集中于将道路损坏分为几种类型。例如，Zhang et al.[20]设计了一种检测两个方向裂缝(即水平和垂直)的方法，而 Akarsu et al.[21]开发了另一种检测三种类型损伤的方法，即水平、垂直和鳄鱼。由于区分损伤类型对于正确的道路维护规划至关重要，Maeda 等人[22]实现了一种对道路损伤类型进行彻底分类的方法。

在这个项目中，我们提出了 YOLOv7 模型，用于检测和分类道路的损坏部分。YOLOv7 算法是一种尖端的对象识别模型，在精度和速度上都超过了你只看一次(YOLO)算法家族的前辈。该算法通过利用其优点，克服其缺点，改进了先前的迭代;它被广泛应用于监控、自动驾驶汽车技术和机器人技术等各个领域。

YOLOv7 算法的优势在于它能够有效地识别和分类实时视频中的物体。为了做到这一点，利用了一个深度神经网络，它已经在大型注释图片数据集上进行了预训练。网络中有几层连接的节点，每一层在目标检测的整体任务中都有不同的目的。为了预测图像或视频帧中物体的存在和位置，构建这些层来识别这些物体的不同特征，例如它们的形状、颜色和纹理。YOLOv7 算法是通用的，因为它可以处理不同形状和大小的对象。这是在特征金字塔网络的帮助下完成的，该网络经过训练，可以识别各种大小和粒度的物体。因此，该算法可以可靠地检测不同大小的物体，即使在许多不同种类的物体彼此靠近的场景中也是如此。YOLOv7 方法运行所需的处理资源也非常少。通过使用轻量级骨干网和其他优化，降低了模型的计算复杂度。由于其功耗要求低，该算法适用于各种环境，包括智能手机和嵌入式系统，在那里它可以实时操作。总体而言，YOLOv7 算法代表了目标检测领域的重大进步，其高精度、快速和高效使其成为广泛应用的热门选择[29-31]。

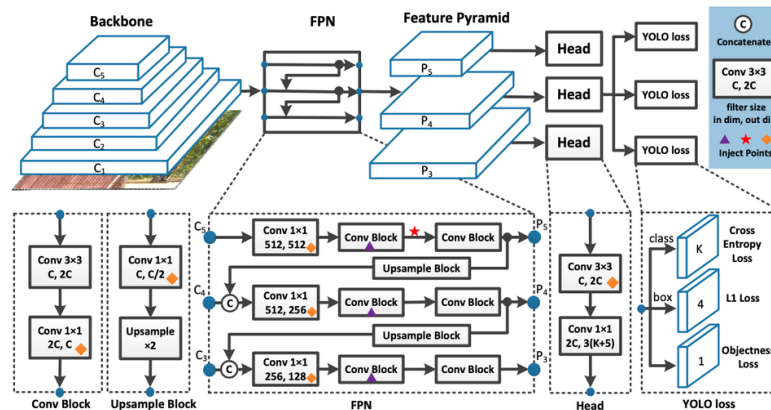


图 2:YOLOv7 的模型架构

在这个版本的 YOLO 算法中有各种各样的模型。这些不同的模型是基于层数和总参数。在本项目中，我们使用 yolov7 模型，该模型相对于 YOLO 版本的其他模型而言，具有较大的宽裕性，计算量相对较少。对于批大小为 32 的模型，该模型在训练过程中的平均时间为 2.8ms，而其他模型如 yolov7-x 为 4.3ms, yolov7-E6E 为 18.7ms[32,33]。

数据集：

在我们的项目中，我们遵循基于众感的道路损伤检测挑战 (CRDDC-2022) [1] 数据集。它们遵循日本道路养护和维修指南 2013 JRA (2013) 的标准。在他们的数据集中有几种类型的裂缝。在视图的基础上，有两种裂缝，一种是线性裂缝，另一种是鳄鱼裂缝。在直线裂缝中有两类裂纹标签，一类为纵向裂纹 D00，一类为横向裂纹 D10。鳄鱼裂纹等级为 D20。我们加入了另一个职业，因为伤害类型是 D40。

Damage Type			Detail	Class Name
Crack	Linear Crack	Longitudinal	Wheel mark part	D00
			Construction joint part	D01
		Lateral	Equal interval	D10
			Construction joint part	D11
	Alligator Crack		Partial pavement, overall pavement	D20
	Other Corruption		Rutting, bump, pothole, separation	D40
Cross walk blur			D43	
White line blur			D44	

Source: Road Maintenance and Repair Guidebook 2013 JRA (2013) in Japan.

Note: In reality, rutting, bump, pothole, and separation are different types of road damage, but it was difficult to distinguish these four types using images. Therefore, they were classified as one class, viz., D40.

绩效：

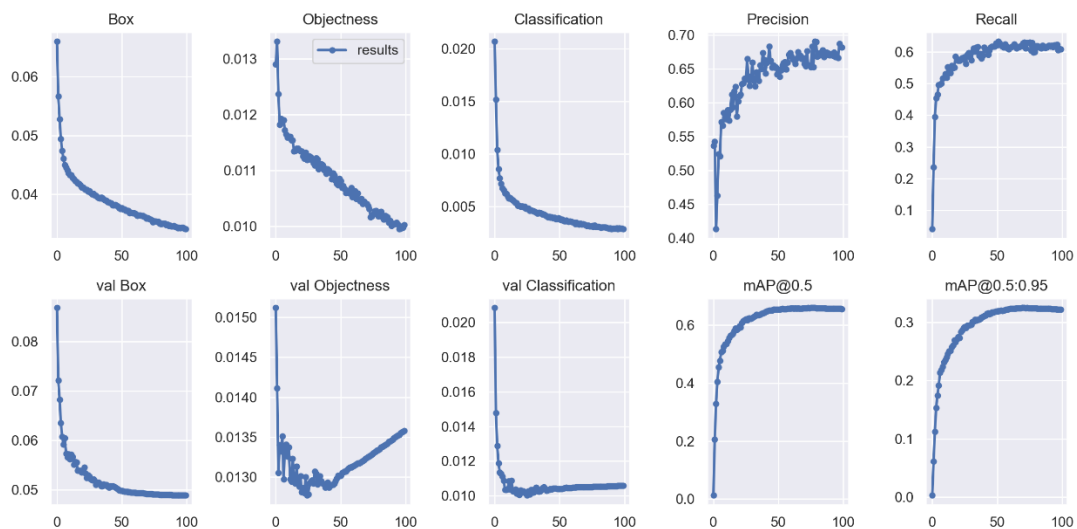


图 3: 训练和验证数据集的包围框、对象和分类的损失值。训练过程中的精密度和召回率曲线




图 4: 预测测试数据的混淆矩阵

在图 3 和图 4 中，我们可以注意到我们的模型正在不断地降低预测对象、包围框和分类的损失值。我们用更少的超参数继续进行了 100 个 epoch 的训练，这有助于我们的模型在更少的 epoch 中进行更具体的训练。由于我们的 GPU 计算设备不足，这次训练我们只运行了 100 个 epoch。然而，从这个结果中我们可以得出结论，在更高配置的 GPU 设备上可以获得更高、更精确、更精确的模型。

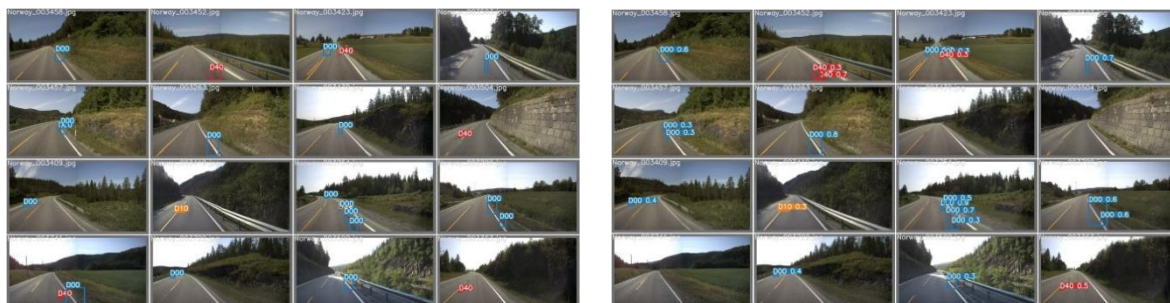


图 5: 在不同镜头上评估训练模型

训练结束后，我们用我们的模型在训练过程中从未遇到过的不同图像做了一个实验。在图 5 中，我们可以看到几乎 85% 以上的损坏道路可以被我们的模型检测到。

应用程序框架和文档:

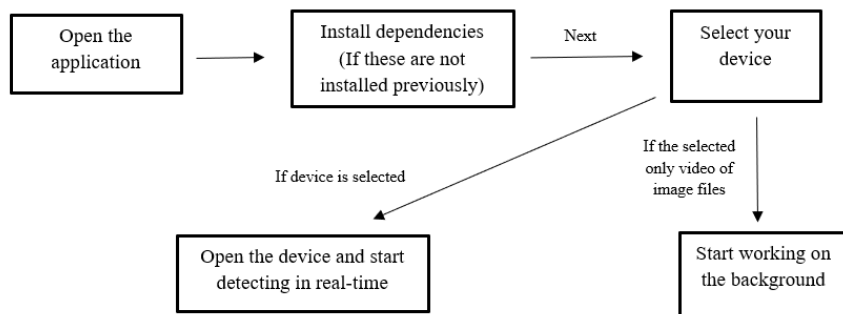
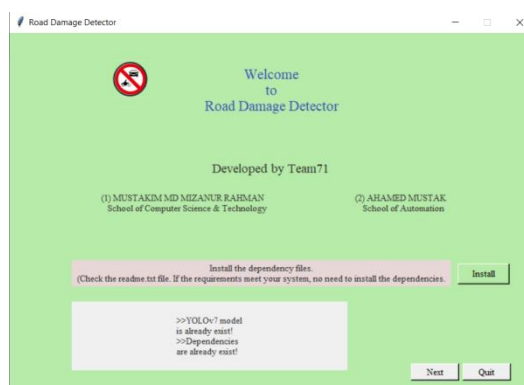


图 6:应用程序管道

我们的应用程序管道非常特定。首先，用户必须在他们的计算机上运行应用程序。然后，如果他们的设备上没有安装依赖项，他们将要求安装依赖项。这可以通过按下界面上的“安装”按钮轻松完成。在消息提示中得到安装成功的消息后，用户将通过按“next”按钮移动到下一个窗口。在新窗口中，可以看到有一些选择来指定检测方法。如果用户想进行实时检测，可以选择“Webcam1”或“Webcam2”，如果用户想使用之前拍摄的视频或图像，可以选择视频或照片复选框。选择检测网关后，用户按下“Test”按钮后，检测过程开始。



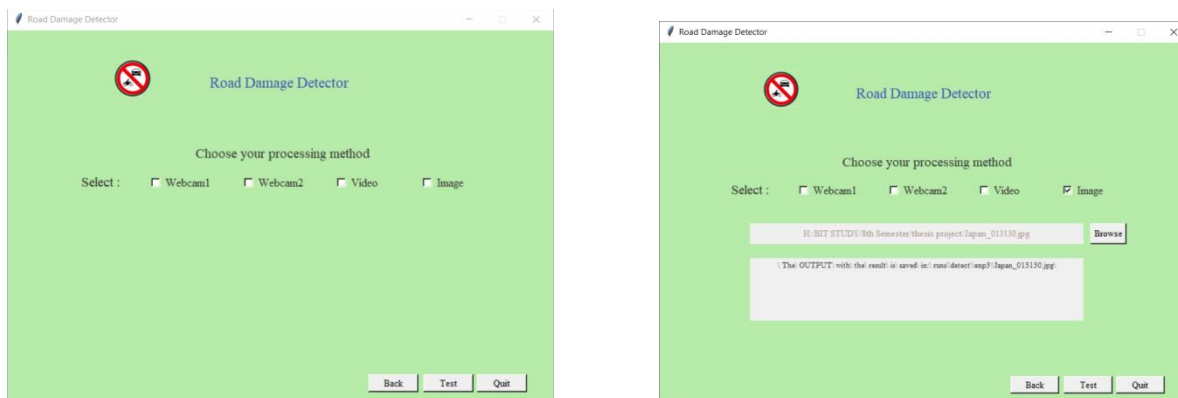


图 7: 我们模型应用程序的用户界面

项目优势:

中国用于识别受损道路的技术包括智能交通系统(ITS)和道路监控系统[34]。ITS 使用传感器和其他先进技术来收集道路状况和交通模式的实时数据，这些数据可用于识别拥堵区域并优先进行维修。道路监测系统包括在道路上安装传感器和其他设备，以收集交通流量和道路状况的数据，然后对这些数据进行分析，以确定受损区域。然而，这是一个成本和许多硬件设置的问题，而我们的系统可以用于任何监控摄像头、无人机或高清摄像头，甚至是计算机网络摄像头。这种应用不需要任何类型的传感器。

此外，我们提出的模型和应用程序是用最新的技术构建的。在目前的技术中，YOLOv7 是开发高性能目标检测模型最热门的话题。总体而言，道路损伤检测研究的科学性和先进性正在推动交通基础设施管理领域取得重大进展。通过开发更准确、更高效的检测模型，这项研究有可能提高道路安全，降低与道路维护和维修相关的成本。

分析:

基于大数据和人工智能的不断发展，缺陷检测已经在很大程度上成为技术驱动。智能摄像头和相关人工智能驱动系统的使用已经在帮助制造商在更短的周期内提供高质量的检查，降低延迟和成本，并建立即使是经验丰富的人类检查人员也无法执行的新任务。2020 年，全球缺陷检测市场规模达到 33.946 亿美元，预计到 2027 年将达到 51.134 亿美元，2021 年至 2027 年期间的复合年增长率为 6.6%。因此，缺陷检测是任何制造质量控制和保证过程的主要组成部分。通常，缺陷检测是由高度容易疲劳、偏见和不注意的人手动执行的。然而，目前人工检测是通过基于规则的机器视觉技术来增强的。

在过去几十年里，中国取得了惊人的经济增长，而中国的交通基础设施一直是支撑这种扩张能力的重要因素。尽管如此，中国道路的退化已经对国家经济产生了巨大的负面影响。路况不佳会导致运输成本上升、旅行时间延长、效率降低，这些都会对中国企业的竞争力产生不利影响，并推高商品和服务的价格。根据世界银行发布的研究，由于基础设施不足，尤其是糟糕的道路状况，中国经济每年损失约 5% 的 GDP。

基于深度学习的道路损伤检测具有广泛的潜在用途和优势。其中一些是:

- **早期发现:**在早期阶段发现道路损坏有助于预防事故和挽救生命。
- **节省成本:**早期检测还有助于节省与大规模道路维修相关的成本，这可能比小规模维修昂贵得多。
- **改善维护:**道路损坏检测可以更好、更有效地维护道路基础设施，有助于确保道路安全和减少交通拥堵。
- **自动检测:**自动道路损坏检测系统可以帮助减少对人工检查的需求，人工检查既耗时又昂贵，而且可能并不总是能识别所有形式的损坏。
- **提高精度:**用于道路损坏检测的深度学习算法可以达到较高的精度，降低误报和误报的风险。
- **可访问性:**道路损坏检测模型的用户友好界面可以使更广泛的用户更容易使用该技术，包括政府机构、私人承包商和个人用户。
- **可扩展性:**基于深度学习的道路损伤检测模型可以根据被监测道路网络的规模和复杂性轻松地放大或缩小。
- **与其他技术集成:**道路损伤检测可以与自动驾驶汽车等其他技术集成，以确保安全可靠运输。

此外，基于深度学习的道路损伤检测可以提高道路安全，降低成本，确保道路基础设施更高效的维护，是交通工程研究的重要领域。

结论:

综上所述，道路损伤检测模型是一项可能对经济和人们日常生活产生重大影响的关键技术。迅速准确地识别受损道路可以减少事故，改善交通流量，并最终挽救生命。此外，这项技术还可以为政府和道路管理部门节省大量成本，使他们能够更有效地确定道路维护和维修的优先次序和时间表。机器学习和计算机视觉技术的进步极大地提高了道路损伤检测模型的精度和速度。使用 YOLOv7 等深度学习方法，大大提高了这些模型的检测精度，同时也降低了它们的计算复杂度，提高了它们的效率。此外，将目标识别技术与卫星图像和激光雷达数据相结合，可以更全面和彻底地了解道路状况，从而更准确和高效地规划道路养护和维修。

总的来说，道路损坏识别模型是一项有前途的技术，可以为社会带来多种好处。其精度、速度和效率使其成为政府和道路管理部门管理和维护道路网络的重要工具。这项技术

有可能改变我们管理道路和交通网络的方式，使它们对每个人来说都更安全、更高效。因此，可以断言，该模型被广泛认为是道路维护和安全不可或缺的工具。

References

- [1]. Arya, D., Maeda, H., Ghosh, S. K., Toshniwal, D., & Sekimoto, Y. (2022). Crowdsensing based Road Damage Detection Challenge (CRDDC-2022). arXiv preprint arXiv:2211.11362.
- [2]. Arya, D., Maeda, H., Ghosh, S. K., Toshniwal, D., & Sekimoto, Y. (2022). RDD2022: A multi-national image dataset for automatic Road Damage Detection. arXiv preprint arXiv:2209.08538
- [3]. Arya, D., Maeda, H., Sekimoto, Y., Omata, H., Ghosh, S. K., Toshniwal, D., Sharma, M., Pham, V. V., Zhong, J., et al. (2022). RDD2022 - The multi-national Road Damage Dataset released through CRDDC'2022 (Version 1). figshare. <https://doi.org/10.6084/m9.figshare.21431547.v1>
- [4]. Arya, D., Maeda, H., Ghosh, S. K., Toshniwal, D., Mraz, A., Kashiya, T., & Sekimoto, Y. (2021). Deep learning-based road damage detection and classification for multiple countries. *Automation in Construction*, 132, 103935. 10.1016/j.autcon.2021.103935
- [5]. Arya, D., Maeda, H., Ghosh, S. K., Toshniwal, D., & Sekimoto, Y. (2021). RDD2020: An annotated image dataset for Automatic Road Damage Detection using Deep Learning. *Data in Brief*, 107133. <<https://doi.org/10.1016/j.dib.2021.107133>>.
- [6]. Arya, D., Maeda, H., Ghosh, S. K., Toshniwal, D., Omata, H., Kashiya, T., & Sekimoto, Y. (2020). Global Road Damage Detection: State-of-the-art Solutions. *IEEE International Conference on Big Data (Big Data)*, Atlanta, GA, USA, 2020, pp. 5533-5539, doi: 10.1109/BigData50022.2020.9377790.
- [7]. Maeda, H., Kashiya, T., Sekimoto, Y., Seto, T., & Omata, H. (2021). Generative adversarial network for road damage detection. *Computer-Aided Civil and Infrastructure Engineering*, 36(1), 47-60.
- [8]. Medsker, L.R. and Jain, L.C., 2001. Recurrent neural networks. *Design and Applications*, 5, pp.64-67.
- [9]. Kim, P. and Kim, P., 2017. Convolutional neural network. *MATLAB deep learning: with machine learning, neural networks and artificial intelligence*, pp.121-147.
- [10]. Tan, M. and Le, Q., 2019, May. Efficientnet: Rethinking model scaling for convolutional neural networks. In *International conference on machine learning* (pp. 6105-6114). PMLR.
- [11]. Deng, J., Dong, W., Socher, R., Li, L.J., Li, K. and Fei-Fei, L., 2009, June. Imagenet: A large-scale hierarchical image database. In *2009 IEEE conference on computer vision and pattern recognition* (pp. 248-255). Ieee.
- [12]. Liu, W., Anguelov, D., Erhan, D., Szegedy, C., Reed, S., Fu, C.Y. and Berg, A.C., 2016. Ssd: Single shot multibox detector. In *Computer Vision—ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11–14, 2016, Proceedings, Part I 14* (pp. 21-37). Springer International Publishing.
- [13]. Redmon, J., Divvala, S., Girshick, R. and Farhadi, A., 2016. You only look once: Unified, real-time object detection. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 779-788).
- [14]. Wu, Y., Kirillov, A., Massa, F., Lo, W.Y. and Girshick, R., 2019. Detectron2.
- [15]. Ren, S., He, K., Girshick, R. and Sun, J., 2015. Faster r-cnn: Towards real-time object detection with region proposal networks. *Advances in neural information processing systems*, 28.
- [16]. He, K., Gkioxari, G., Dollár, P. and Girshick, R., 2017. Mask r-cnn. In *Proceedings of the IEEE international conference on computer vision* (pp. 2961-2969).
- [17]. B. X. Yu and X. Yu, "Vibration-based system for pavement condition evaluation," in *AATT*, 2006, pp. 183–189.
- [18]. Q. Li, M. Yao, X. Yao, and B. Xu, "A real-time 3d scanning system for pavement distortion inspection," *MST*, vol. 21, no. 1, p. 015702, 2009.
- [19]. A. Zhang, K. C. Wang, B. Li, E. Yang, X. Dai, Y. Peng, Y. Fei, Y. Liu, J. Q. Li, and C. Chen, "Automated pixel-level pavement crack detection on 3d asphalt surfaces using a deep-learning network," *CACAIE*, vol. 32, no. 10, pp. 805–819, 2017.
- [20]. L. Zhang, F. Yang, Y. D. Zhang, and Y. J. Zhu, "Road crack detection using deep convolutional neural network," in *ICIP. IEEE*, 2016, pp. 3708–3712.
- [21]. B. Akarsu, M. KARAKOSE, K. PARLAK, A. Erhan, and A. SARI- " MADEN, "A fast and adaptive road defect detection approach using computer vision with real time implementation," *IJAMEC*, vol. 4, no. Special Issue-1, pp. 290–295, 2016.
- [22]. H. Maeda, Y. Sekimoto, T. Seto, T. Kashiya, and H. Omata, "Road damage detection and classification using deep neural networks with smartphone images," *CACAIE*.

- [23]. A. Alfarrarjeh, S. H. Kim, S. Agrawal, M. Ashok, S. Y. Kim, and C. Shahabi, "Image classification to determine the level of street cleanliness: A case study," in BigMM. IEEE, 2018.
- [24]. S. H. Kim, J. Shi, A. Alfarrarjeh, D. Xu, Y. Tan, and C. Shahabi, "Realtime traffic video analysis using intel viewmont coprocessor," in DNIS. Springer, 2013, pp. 150–160.
- [25]. A. Alfarrarjeh, S. Agrawal, S. H. Kim, and C. Shahabi, "Geo-spatial multimedia sentiment analysis in disasters," in DSAA. IEEE, 2017, pp. 193–202.
- [26]. A. Alfarrarjeh, C. Shahabi, and S. H. Kim, "Hybrid indexes for spatialvisual search," in ACM MM Thematic Workshops. ACM, 2017, pp. 75–83.
- [27]. Kamaruddin, I., Singh, L., & Sudin, I. (2019). Classification of Road Surface Defects: A Review. *Journal of Engineering Science and Technology*, 14(3), 1473-1495.
- [28]. World Bank. (2013). *China 2030: Building a Modern, Harmonious, and Creative Society*. Washington, DC: World Bank.
- [29]. Bochkovskiy, A., Wang, C. Y., & Liao, H. Y. M. (2021). YOLOv7: Real-time object detection revisited. arXiv preprint arXiv:2103.09460.
- [30]. Redmon, J., & Farhadi, A. (2018). YOLOv3: An incremental improvement. arXiv preprint arXiv:1804.02767.
- [31]. Redmon, J., Divvala, S., Girshick, R., & Farhadi, A. (2016). You only look once: Unified, real-time object detection. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 779-788).
- [32]. Wang, C., Liao, H., & Yeh, I. (2022). Designing Network Design Strategies Through Gradient Path Analysis. ArXiv. /abs/2211.04800
- [33]. Wang, C., Bochkovskiy, A., & Liao, H. (2022). YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors. ArXiv. /abs/2207.02696
- [34]. China Daily. (2019). China seeks smart solutions to fix crumbling roads. Retrieved from <https://www.chinadaily.com.cn/a/201908/06/WS5d49b0f6a310cf3e35563f75.html>